

基于手机传感器识别行人步态的 PSO-ELM 算法

郭 英, 李兆博, 刘如飞, 黄昊东

(山东科技大学 测绘与空间信息学院, 青岛 266590)

摘要: 针对因手机携带位置不同对传感器产生干扰而导致行人步态识别准确率降低的问题, 提出了一种粒子群优化极限学习机 (PSO-ELM) 识别算法。首先, 基于极限学习机 (ELM) 分类方法, 借助分层 ELM 多层降维的特点, 利用粒子群优化算法对 ELM 算法参数进行寻优, 设计有效识别行人手机携带位置的分层 PSO-ELM 分类方法。然后, 通过线性判别分析的降维算法和 PSO-ELM 完成对行人步态的有效识别。实验使用 Android 手机对五种携带位置四种步态下的加速度和角速度数据进行采集, 结果表明: 在识别手机携带位置层面, 训练集与测试集的识别准确率分别达到 99.54%、99.47%; 在识别行人步态层面, 两种准确率分别达到 95.74%、95.31%, 证明所提算法具有较高的步态识别准确率。

关键词: 行人步态识别; 手机传感器; 极限学习机; 粒子群优化算法; 线性判别分析

中图分类号: TP391.4; TP181

文献标志码: A

PSO-ELM algorithm for pedestrian gait recognition through mobile phone sensors

GUO Ying, LI Zhaobo, LIU Rufe, HUANG Haodong

(College of Geodesy and Geomatics, Shandong University of Science and Technology, Qingdao 266590, China)

Abstract: Aiming at the problem that the accuracy of pedestrian gait recognition is reduced due to the interference of sensors caused by different positions of mobile phones, a particle swarm optimization-extreme learning machine (PSO-ELM) recognition algorithm is proposed. Firstly, based on the classification method of ELM and the characteristics of multi-level dimension reduction of hierarchical ELM, PSO algorithm is used to optimize the parameters of ELM model, and a hierarchical PSO-ELM classification method is designed to effectively identify the location of pedestrians' mobile phones. Then, through the dimensionality reduction algorithm of linear discriminant analysis and PSO-ELM, the effective recognition of pedestrian gait is completed. In the experiments, the acceleration and angular velocity data under four gaits of five carrying positions are collected by Android phones. The results show that the recognition accuracy of the training set and the test set are 99.54% and 99.47% at the level of identifying the carrying position of the mobile phone. At the level of identifying pedestrian gait, the accuracy of the two sets reach 95.74% and 95.31%, which proves that the proposed algorithm has high gait recognition accuracy.

Key words: pedestrian gait recognition; mobile phone sensors; extreme learning machine; particle swarm optimization algorithm; linear discriminant analysis

智能手机是当今社会大多数人群必备的携带工具。利用手机传感器识别行人步态的技术逐渐兴起, 该项技术在健身锻炼^[1]、老年人监护^[2]、室内定位与导航^[3]等多种领域得以应用, 发展前景广阔。

在利用手机传感器识别行人步态上, 开展了不同

理论和应用方面的研究。早期实验^[4,5]通过将手机分别置于腰部、裤袋等单一携带位置, 利用朴素贝叶斯、支持向量机、卷积神经网络等算法识别行人的不同步态。随着智能手机传感器的不断增多, 手机用途更为广泛, 如估测行人的航向^[6]、步数^[7]等, 手机携带方式

收稿日期: 2023-11-04; **修回日期:** 2024-07-22

基金项目: 国家自然科学基金 (42001397)

作者简介: 郭英 (1973—), 女, 副教授, 硕士生导师, 从事室内定位研究。

更为灵活,加之不同行人间同种步态的自身差异性,给使用手机识别行人的具体行为带来了一定的挑战。衡霞等^[8]通过支持向量机对三种手机携带位置下的五种行人步态数据进行识别,识别率为 87.17%; Qamar 等^[9]通过随机森林对三种手机携带位置下的 11 种行人步态数据进行识别,识别率为 91.70%; Daniel 等^[10]将长短期记忆神经网络与卷积神经网络相结合,对手机携带位置不固定的四种行人步态数据进行识别,识别率为 94.80%。因而可知,若不进行任何前置处理,手机在不同携带位置下采集到的数据会相互混淆,致使提取到的数据特征不足以实现明显区分,既会使识别的复杂度提升,又无法保证行人步态的识别准确率。

另一方面,极限学习机(Extreme Learning Machine, ELM)具有学习速度快、泛化能力强的优点,于模式识别凸显优势^[11],引起了行人步态识别领域的学者关注,如 Rubio-Solis 等^[12]根据二型模糊逻辑系统与 ELM,建立由多层二型模糊自编码器和基于多输入多输出二型径向基函数的极限学习机分类器组成的学习模型,根据大腿、小腿、脚三处采集的数据识别平地走、上坡和下坡三种步态,识别率为 99.98%。Tang 等^[13]将 ELM 与多层前向编码算法相结合,通过多层前向编码对数据进行逐步降维以解决 ELM 对数据质量较为敏感的问题,并由此提出了分层极限学习机(Hierarchical Extreme Learning Machine, HELM)的分类与识别算法。文献[14]和文献[15]证明这种算法在电力系统的故障诊断、新生胎儿的心率识别等方面都有较不错的表现。由此来看,如果将 ELM 与降维或寻优方法合理融合,就可以解决其对数据质量较为敏感、难以确定最佳分类性能模型参数问题,更好地对行人步态进行识别。

粒子群优化(Particle Swarm Optimization, PSO)算法是一种根据飞鸟群觅食活动的规律性而提出的随机搜索优化算法^[16],因其群体智能的协同搜索策略和算法本身的简便高效性而在复杂的优化问题中表现出色,被广泛应用于具有识别性能的函数优化^[17]、神经网络训练^[18]等科学研究和工程应用领域。而在分类问题上,文献[19]对数据采用了线性判别分析(Linear Discriminant Analysis, LDA)算法,通过投影降维对原始数据的主要特征信息进行提取。相比于其他降维算法,该算法在保证数据低冗余度的同时也使数据之间的分离度更为明显,为进一步准确分类识别数据提供了保障。

基于此,本文在分析 ELM 的基础上,结合 HELM 多层前向编码的优点,对特征数据进行逐步降维,利用 PSO 对模型参数寻优,进而分类并识别手机携带位

置;基于识别的手机携带位置,利用 LDA 对分类后的原特征数据进行降维,再利用 PSO 寻优 ELM 模型参数,完成常见的几种行人步态识别。

1 ELM 的分类原理

ELM 是一种单隐层的前馈神经网络,通过随机初始化输入权重和偏置,以最小化训练误差为目标进行计算与训练,得到相应的输出权重,进而实现数据分类^[11]。该算法具有训练参数少、学习速度快、泛化能力强等特点,解决了神经网络训练耗时长和资金成本高等问题。ELM 的分类原理为:

假定输入数据为 $X = [x_1, x_2 \cdots x_n]^T$, 期望输出为 $T = [t_1, t_2 \cdots t_n]^T$, 其中 n 为数据总量。ELM 模型可表示为:

$$\sum_{i=1}^k \beta_i \cdot [g(\omega_i \cdot x_j + b_i)] = t_j, j=1, 2 \cdots n \quad (1)$$

其中, k 为 ELM 隐藏层节点个数; ω_i 为连接第 i 个隐藏层节点与输入层节点的输入权重; b_i 为第 i 个隐藏层节点的输入偏置; β_i 为连接第 i 个隐藏层节点与输出层节点的输出权重; $g(\cdot)$ 为激活函数,本文采用 sigmoid 函数作为激活函数。

将由 $g(\omega_i \cdot x_j + b_i)$ 的构成矩阵作为隐藏层输出 H , 则式(1)可表示为:

$$H \cdot \beta = T \quad (2)$$

$$\text{其中, } H = \begin{bmatrix} g(\omega_1 x_1 + b_1) & \cdots & g(\omega_k x_1 + b_k) \\ \vdots & \ddots & \vdots \\ g(\omega_1 x_n + b_1) & \cdots & g(\omega_k x_n + b_k) \end{bmatrix},$$

$$\beta = [\beta_1, \beta_2 \cdots \beta_k]^T.$$

经过输入权重矩阵 $W = [\omega_1, \omega_2 \cdots \omega_k]^T$ 与输入偏置矩阵 $B = [b_1, b_2 \cdots b_k]^T$ 的计算,解得输出权重矩阵 β 。

为进一步提高 ELM 的泛化能力与鲁棒性,将训练过程与正则化方法相结合,加入行列数与 $H^T H$ 相同的由单位矩阵 I 和惩罚系数 C 组成的正则项 I/C , 得到最终的输出权重矩阵。

$$\beta = \left(H^T H + \frac{1}{C} I \right)^{-1} H^T \cdot T \quad (3)$$

2 基于 PSO-ELM 的行人步态识别算法

2.1 基于 HELM 和 PSO 识别手机携带位置

2.1.1 利用 HELM 对特征数据降维与分类

ELM 属于监督特征分类的神经网络,HELM 是基于 ELM 的扩展^[13],原理如图 1 所示。首先,将数据利用无监督的多层前向编码模块完成逐步降维,提取出数据的主要特征;然后,进入 ELM 的单隐层分类

模块。由于 HELM 在对数据进行降维时不需要标签信息, 所以其具有更强大的学习能力, 适用于处理更广泛的数据。

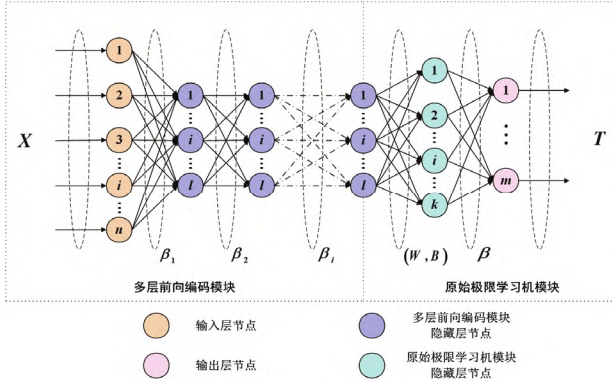


图1 HELM 的网络结构

Fig.1 The network structure of HELM

利用 HELM 识别手机携带位置, 对四种行人步态下五种手机携带位置的数据进行降维与分类。在多层前向编码模块对特征数据进行处理时, 每一层的隐藏层都被视为一个独立的 ELM 自编码器, 每层隐藏层的输入矩阵也是该层的输出矩阵, 通过 $g(\omega_i \cdot x_j + b_i)$ 的映射, 得到该隐藏层的输出权重矩阵 β_i 。

$$H_{i(\text{Output})} = H_{i(\text{Input})} \cdot \beta_i \quad (4)$$

其中, $H_{i(\text{Output})}$ 为第 i 层隐藏层的输出矩阵; $H_{i(\text{Input})}$ 为第 i 层隐藏层经过 $g(\omega_i \cdot x_j + b_i)$ 映射的输入矩阵。

将经过输出权重矩阵处理后的特征数据作为下一隐藏层的输入矩阵和输出矩阵。

$$H_{i+1} = g(H_{i(\text{Output})} \cdot \beta_i) \quad (5)$$

其中, H_{i+1} 为第 $i+1$ 层隐藏层的输入矩阵。

直至多层前向编码模块的隐藏层训练结束、特征数据处理完毕后, 保存每层隐藏层的输出权重矩阵, 并将处理后的特征数据传输至极限学习机模块进行分类。

利用 HELM 的多层前向编码模块对特征数据进行降维处理, 能更充分地显示数据特征, 为后面 ELM 分类提供可靠的特征数据, 有利于手机携带位置的识别。

2.1.2 PSO 算法对 ELM 的优化工作

PSO 算法是一种基于群体协作的随机搜索优化算法, 具有易实现、收敛快、精度高等优点, 能够快速精准地找到全局最优解^[16], 其工作原理为:

根据飞鸟群觅食活动的规律性, 将每个优化问题的解看作搜索空间中的一个“粒子”。每个粒子从随机解出发, 根据式(6)和式(7)更新自己的速度和位置, 通过迭代寻找最优适应度, 以此追踪粒子本身找到的最优解和整个种群找到的最优解。

$$V_i(t+1) = \omega \cdot V_i(t) + c_1 \cdot r_1 \cdot [P_{i(\text{best})} - L_i(t)] + c_2 \cdot r_2 \cdot [G_{(\text{best})} - L_i(t)] \quad (6)$$

$$L_i(t+1) = L_i(t) + V_i(t) \cdot 1 \quad (7)$$

其中, t 为迭代次数; $V_i(t)$ 表示第 i 个粒子在第 t 次迭代时的速度; ω 为惯性权重; c_1 、 c_2 分别为个体学习因子和社会学习因子; r_1 、 r_2 分别为个体学习随机系数和社会学习随机系数; $P_{i(\text{best})}$ 表示第 t 次迭代时粒子本身找到的个体最优解; $G_{(\text{best})}$ 表示第 t 次迭代时整个种群找到的全局最优解; $L_i(t)$ 表示第 i 个粒子在第 t 次迭代时的位置。

为了提高 ELM 识别的鲁棒性, 利用 PSO 优化 HELM 中 ELM 模块的输入权重 W 和输入偏置 B , 构建粒子群优化的极限学习机 (PSO-ELM) 分类算法来寻找最优结果, 具体流程如图 2 所示。

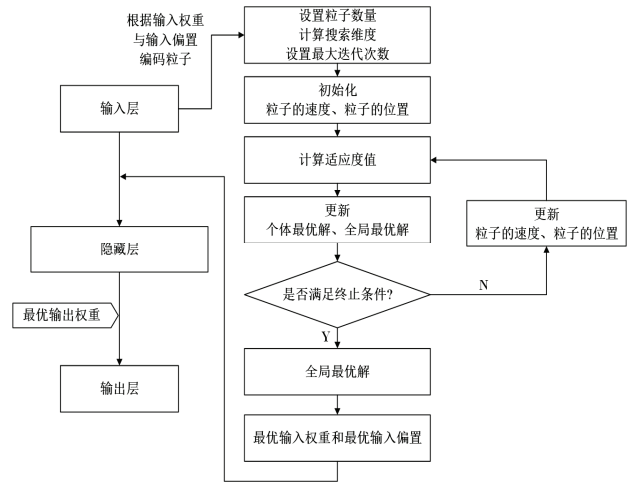


图2 PSO-ELM 的计算流程

Fig.2 Flow of PSO-ELM algorithm

首先, 将输入权重矩阵 W 与输入偏置矩阵 B 中的每个值作为粒子群优化的粒子, 在 PSO 的参数空间中不断迭代, 寻找具有最优分类效果的参数解作为连接 ELM 隐藏层与输入层的最优 W 和 B ; 然后, 通过 ELM 求得连接隐藏层与输出层的最优输出权重矩阵, 完成分类识别。PSO-ELM 解决了 ELM 中 W 和 B 由于随机初始化而难以寻求满足最佳分类性能的模式参数问题, 提高了学习效果的稳定性和鲁棒性。

2.2 行人步态的识别方法

原始数据的特征信息冗杂, 通过降维提取其主要信息有利于进一步的数据处理。LDA 通过最大化类间散布度和类内散布度的比值, 确定最佳分类的投影方向。数据在按该方向投影后, 采取同类型数据点尽可能接近、异类型数据点尽可能远离的方式实现了数据的压缩降维^[19]。相比于 HELM 的压缩降维, LDA 具有监督性, 即提前知道了数据的标签信息, 这使得带

标签的高维数据投影到低维空间后, 不同类别数据之间的差异性最大化, 分离度更为明显。LDA 的降维原理为:

对于具有 m 种类别的 n 个输入数据, 其类内散布度 S_w 和类间散布度 S_b 可表示为:

$$S_w = \frac{1}{n} \sum_{i=1}^m \sum_{j=1}^{n_i} (\mathbf{x}_{i,j} - \bar{\mathbf{x}}_i)(\mathbf{x}_{i,j} - \bar{\mathbf{x}}_i)^T \quad (8)$$

$$S_b = \frac{1}{n} \sum_{i=1}^m n_i (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T \quad (9)$$

其中, n_i 为第 i 种类别中数据的总量; $\mathbf{x}_{i,j}$ 为第 i 种类别中第 j 个数据值; $\bar{\mathbf{x}}_i$ 为第 i 种类别中所有数据的平均值; $\bar{\mathbf{x}}$ 为所有数据的平均值。

建立二者的比例函数 $J(\mathbf{Q})$ 如式(10)所示, 通过将该函数最大化以求得最好和最易于分类的投影方向 \mathbf{Q} 。根据 \mathbf{Q} 值对数据进行投影, 从而实现数据的压缩

降维。

$$J(\mathbf{Q}) = \frac{\mathbf{Q}^T S_b \mathbf{Q}}{\mathbf{Q}^T S_w \mathbf{Q}} \quad (10)$$

确定了手机携带位置后, 利用 LDA 进行有监督的降维, 然后再通过 2.1.2 节的 PSO-ELM 算法实现行人步态识别。

综上所述, 通过对手机中的加速度计和陀螺仪数据进行峰值检测, 分割出运动过程中的步频, 并对其 X 轴、 Y 轴、 Z 轴的加速度数据、角速度数据及整体的加速度模值数据提取出如表 1 所示的时域特征项, 作为行人手机携带位置和步态识别的输入量。利用分层粒子群优化极限学习机 (H-PSO-ELM) 识别手机的携带位置, 再利用 LDA 和 PSO-ELM 进行分类, 完成行人步态的有效识别。

表 1 时域特征项的计算公式与作用

Tab.1 Calculation formula and function of time domain characteristic items

特征项	计算公式	作用
总值	$\sum_{i=1}^n x_i$	评价数据的总体大小
均值	$\frac{1}{n} \sum_{i=1}^n x_i$	评价数据的集中趋势
方差	$\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$	评价数据的离散程度与波动性
标准差	$\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$	评价数据的离散程度与波动性
偏度	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\sigma^3}$	评价数据的偏斜程度与对称性
峰度	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\sigma^4} - 3$	评价数据的尖顶程度
一阶差分绝对和	$\sum_{i=2}^n x_i - x_{i-1} $	评价相邻数据之间的趋势变化情况
相邻两点变化绝对值的平均值	$\frac{1}{n-1} \sum_{i=2}^n x_i - x_{i-1} $	评价相邻数据之间的平均趋势变化情况
绝对能量	$\sum_{i=1}^n x_i^2$	评价数据的能量大小
分组熵	$-\sum_{j=1}^k p_j \log_2 p_j$ p_j 为第 j 组 x_i 的数据分布概率	评价数据的集中程度与均匀性
近似熵	$\phi^m(r) - \phi^{m+1}(r)$ $\phi^m(r) = \frac{1}{n-m+1} \sum_{i=1}^{n-m+1} \ln \frac{c_i^m(r)}{n-m+1}$ $c_i^m(r)$ 为与以 x_i 开始且长度为 m 的子序列相距小于等于 r 的相同长度其他子序列的数量	评价数据的复杂程度与不规则性

3 实验与分析

3.1 数据采集与处理

3.1.1 数据采集

尽管手机随携带位置信息或行人步态信息相似,但由于行人存在性别、年龄、身高、体重等个体因素之间的差异,导致加速度计和陀螺仪信号特征信息存在一定程度的变化,从而影响算法识别的可靠性。为此,实验寻找了年龄位于 20~60 岁、身高在 150~185 cm 之间、体重在 45~95 kg 之间、由三名男性和三名女性组成的志愿者(见表 2),让他们将智能手机置于手中(使用)、手中(通话)、手中(摆臂)、裤袋位置、双肩包位置这五种携带位置,进行走、跑、上楼、下楼这四种日常步态的运动,采样频率为 50 Hz、采样时间为 50 s,采集共计 20 种、120 组运动过程的加速度和角速度数据。每一组采集数据经过步频分割、提取时域特征的处理后,随机选取其中 80%作为训练集,剩余 20%作为测试集。

表 2 数据采集者信息
Tab.2 Data information of the collectors

编号	性别	年龄/岁	身高/m	体重/kg	手机型号
实验者 1	女	20	1.57	45.3	OPPO A2P
实验者 2	女	35	1.70	60.9	HUAWEI
实验者 3	女	50	1.63	51.6	Redmi K60E
实验者 4	男	25	1.72	76.2	Redmi K60E
实验者 5	男	48	1.82	92.2	HUAWEI
实验者 6	男	60	1.77	81.5	OPPO A2P

3.1.2 模型参数设置

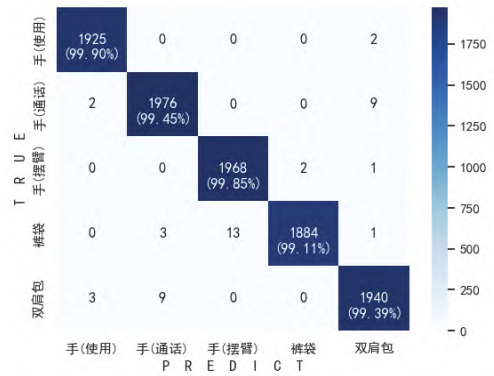
在识别手机携带位置时,隐藏层的层数与每层对应的节点数是影响 HELM 分类性能的重要参数:若层数和节点数过少,则模型难以捕捉到深层特征信息,导致分类效果不好;若层数和节点数过多,则会增加模型计算复杂度,也会使模型过拟合,影响分类效果。因此,本文将 HELM 隐藏层数量设置为 3,每层节点数分别设为 50、20、40。利用 PSO 优化 ELM 模块时,将分类准确率高低作为粒子适应度优劣的评判标准,其他参数参考文献[20]。经过反复实验,设置 $t=50$ 、 $\omega=0.8$ 、 $c_1=c_2=1.8$ 、 $r_1=0.8$ 、 $r_2=0.3$ 。在识别行人步态阶段,

根据不同的手机携带位置,对原特征数据进行标准化,利用 LDA 将数据约简为三维,继而建立相应的 PSO-ELM 识别模型,模型的隐藏层节点数设置为 20,PSO 中各参数、适应度评判标准保持不变。

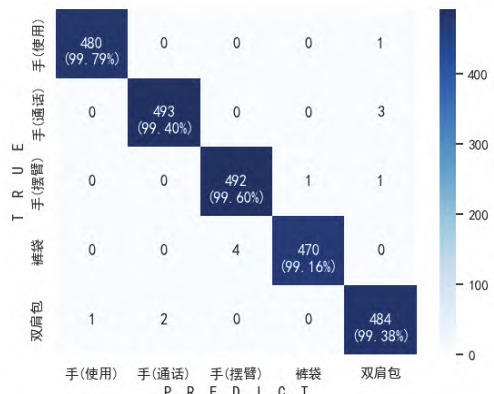
3.2 数据处理结果与分析

3.2.1 手机携带位置识别实验结果与分析

利用上述采集的数据,经过步频分割和特征提取后,采用 H-PSO-ELM 算法识别手机携带位置,其训练结果与测试结果的混淆矩阵如图 3 所示。为了验证本文算法的可靠性,将其与仅采用 ELM 的算法和没有经过 PSO 处理的 HELM 算法进行对比,识别结果如表 3 所示。



(a) 训练集分类结果混淆矩阵
(a) Confusion matrix on training set



(b) 测试集分类结果混淆矩阵
(b) Confusion matrix on test set

图 3 手机携带位置分类模型的混淆矩阵

Fig.3 Confusion matrices of mobile phone carrying position classification model

表 3 不同算法的识别性能对比

Tab.3 Comparison of recognition performance of different algorithms

分类算法	训练集				测试集			
	准确率	精确率	召回率	F1-分数	准确率	精确率	召回率	F1-分数
ELM	97.05%	97.09%	97.06%	97.07%	96.42%	96.47%	96.43%	96.44%
HELM	98.29%	98.30%	98.29%	98.30%	97.94%	97.95%	97.96%	97.95%
H-PSO-ELM	99.54%	99.54%	99.54%	99.54%	99.47%	99.47%	99.47%	99.47%

由图 3 和表 3 分析可知:

1) 利用 H-PSO-ELM 进行手机携带位置识别, 五种携带位置下训练集的识别率略高于测试集的识别率。其中手(使用)位置的识别率最高, 训练集和测试集的识别准确率均大于 99.5%, 这是因为手机持于手中置于胸前, 与其他位置相比, 手机相对于人体较为稳定, 受到行进产生震动的干扰小, 容易进行区分; 而处于裤袋位置时双腿的交替行进使得步态运动产生的数据变化, 与手机置于手(摆臂)位置因手的摆动而产生的规律性大致相似, 但由于缺乏手的稳定作用, 且更靠近腿部这一震动源, 导致数据表现出更大的变异性, 因此识别率较低。

2) 通过不同算法之间的对比可以发现, 仅采用 ELM 进行分类识别, 识别率比较低; 采用 HELM 进行分层降维后再分类识别, 识别率有较大提高; 利用 PSO 为 HELM 分类提供最优的模型参数, 得到的识别率均大于 99.0%。因此, 利用经过 PSO 优化的 HELM 算法(H-PSO-ELM)的手机携带位置识别方法的可靠性和鲁棒性较好。

3.2.2 手机携带位置分类下的行人步态识别实验结果与分析

将原特征数据经过手机携带位置识别的划分后, 进一步利用 LDA 进行降维处理。以手机位于裤袋位置的行人步态训练集数据为例, 选取降维前数据的任意三个维度(这里分别为 X 轴加速度数据的偏度、 Z 轴角速度数据的方差、加速度模值数据的近似嫡)以及经过降维计算得出的三个维度, 通过散点图的方式对 LDA 降维处理前后的数据进行可视化, 结果如图 4 所示。经过对比发现, LDA 将原本混杂在一起的数据进行了优化, 使得这四种行人步态数据同类型之间尽可能接近、异类型之间尽可能远离, 在减少数据冗余度的同时也提升了数据的质量。

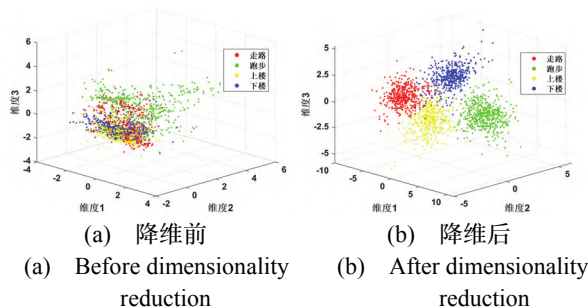


图 4 LDA 降维前后数据点分布的对比
Fig.4 Comparison of data point distribution before and after LDA dimensionality reduction

LDA 降维后各手机携带位置的行人步态数据散点图如图 5 所示, 可以看出各种步态数据之间均有了明显的分离度, 有利于进行后续 PSO-ELM 算法的行人步态识别工作。

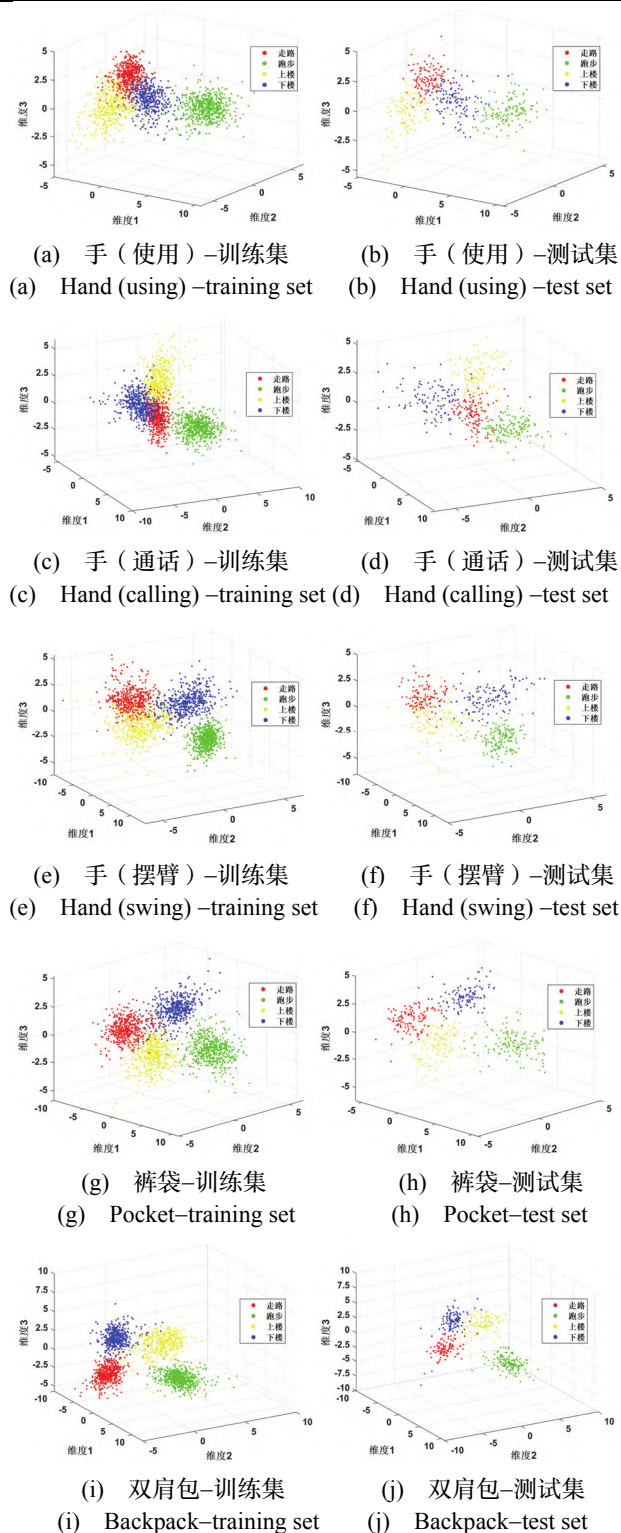


图 5 LDA 降维后各手机携带位置的行人步态数据散点图
Fig.5 Scatter plot of pedestrian gait data at each mobile phone carrying position after LDA dimensionality reduction

通过 PSO-ELM 算法识别降维数据的步态, 得到的训练结果与测试结果的混淆矩阵如图 6 所示, 每种手机携带位置下行人步态分类模型的训练集与测试集的平均识别精度如表 4 所示。分析可知, 跑步的幅度较大, 识别准确率高于 99.5%, 而走路与上楼、下楼的步态动作本身具有一定的相似性, 且台阶高度、台

阶面长度等环境因素使得这三种步态在行进速度上又大致类似, 导致走路、上楼、下楼在识别时容易发生混淆, 因此识别准确率相较于跑步而言不高; 各携带位置行人步态分类模型的训练集与测试集的分类精度

均在 92.5%以上, 因双肩包位于身体后方, 手机紧贴于身体, 增强了每种步态下传感器信息变化的规律性, 识别效果较好。

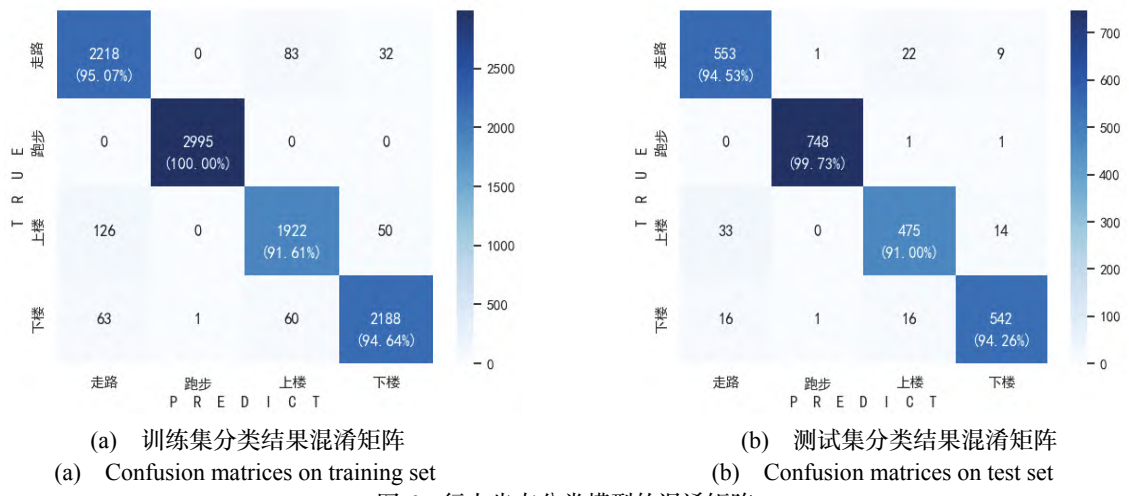


图 6 行人步态分类模型的混淆矩阵

Fig.6 Confusion matrices of pedestrian gait classification model

表 4 每种手机携带位置对应的 PSO-ELM 行人步态分类模型的识别性能

Tab.4 Recognition performance of PSO-ELM pedestrian gait classification model corresponding to each mobile phone carrying position

携带位置	训练集				测试集			
	准确率	精确率	召回率	F1-分数	准确率	精确率	召回率	F1-分数
手 (使用)	93.52%	93.13%	92.98%	93.04%	93.14%	92.76%	92.64%	92.69%
手 (通话)	94.47%	94.05%	93.93%	93.97%	93.94%	93.50%	93.31%	93.38%
手 (摆臂)	94.04%	93.40%	93.39%	93.38%	93.75%	93.02%	93.01%	93.00%
裤袋	97.40%	97.29%	97.25%	97.26%	97.03%	96.92%	96.87%	96.88%
双肩包	99.33%	99.31%	99.23%	99.26%	98.77%	98.65%	98.66%	98.65%

3. 2. 3 行人步态识别综合实验结果与分析

为了进一步验证本文算法的鲁棒性, 将行人步态识别的多种情况进行比较和分析: 实验 1 是利用 LDA 降维与 PSO-ELM 分类算法直接识别行人的步态; 实验 2 为 H-PSO-ELM 手机携带位置识别后, 再利用 LDA 与卷积神经网络识别行人步态; 实验 3 为 H-PSO-ELM 手机携带位置识别后, 再利用 LDA 与支持向量机识

别行人步态; 实验 4 为 H-PSO-ELM 手机携带位置识别后, 再利用 H-PSO-ELM 识别行人步态; 实验 5 为 LDA 和 PSO-ELM 手机携带位置识别后, 再利用 LDA 和 PSO-ELM 识别行人步态; 实验 6 为本文算法, 即 H-PSO-ELM 手机携带位置识别后, 再利用 LDA 和 PSO-ELM 识别行人步态。各实验识别结果的具体精度如表 5 所示。

表 5 不同算法的识别性能对比

Tab.5 Comparison of recognition performance of different algorithms

实验	训练集				测试集			
	准确率	精确率	召回率	F1-分数	准确率	精确率	召回率	F1-分数
实验 1	82.27%	80.86%	80.79%	80.79%	81.95%	80.55%	80.48%	80.49%
实验 2	93.13%	92.70%	92.61%	92.64%	92.60%	92.17%	92.11%	92.13%
实验 3	93.80%	93.38%	93.29%	93.32%	93.22%	92.80%	92.77%	92.78%
实验 4	94.23%	93.82%	93.73%	93.76%	93.71%	93.30%	93.25%	93.27%
实验 5	94.11%	93.70%	93.60%	93.64%	93.67%	93.27%	93.20%	93.23%
实验 6	95.74%	95.39%	95.33%	95.35%	95.31%	94.94%	94.88%	94.90%

分析表 5 可知:

1) 实验 1 对手机携带位置不进行识别等处理, 直

接利用 LDA 与 PSO-ELM 对行人步态进行一次性识别, 识别率较低, 仅在 80%以上。

2)实验 2 和实验 3 采用不同算法先进行手机携带位置的识别,再进行行人步态识别。将实验 6 与二者对比,就测试集的识别准确率而言,分别提升了 2.71% 和 2.09%,证明本文算法的识别效果更优。

3)实验 4 利用 H-PSO-ELM 先识别手机携带位置再识别行人步态,实验 5 利用 LDA 和 PSO-ELM 先识别手机携带位置再识别行人步态。从指标参数来看,实验 6 先利用 H-PSO-ELM 识别手机携带位置再利用 LDA 和 PSO-ELM 识别行人步态的识别精度更高。这是因为在识别手机携带位置时,五种手机携带位置数据混杂在一起,每种手机携带位置数据又包含着四类行人步态信息,数据更复杂,且同种数据之间的变化维度更广,H-PSO-ELM 的多层前向编码模块通过隐藏层层与层之间的信息处理与传递具有了强大的学习能力,适用于复杂化数据的处理与识别,因此相比于实验 4,实验 6 在最终行人步态识别测试集上的准确率提升了 1.60%;行人步态识别是在单个种类手机携带位置下对四种行人步态数据进行识别,LDA 通过标签提取数据中最为相关的有用信息,使得数据分类更准确,因此相比于实验 5,实验 6 在测试集的识别准确率上提升了 1.64%,从而证明了本文识别算法的可靠性和鲁棒性较高。

4 结论

随着智能手机成为国内外大多数人群必备的携带工具,基于手机传感器识别人体行为的研究逐步发展。本文基于学习速度快、泛化能力强的 ELM 算法,借助 HELM 多层降维的特点,利用 PSO 算法对 ELM 模型参数进行寻优并构建 PSO-ELM 模型,建立识别行人手机携带位置的 H-PSO-ELM 分类方法;再通过 LDA 的降维算法和 PSO-ELM,完成对行人步态的识别。实验使用 Android 手机采集五种携带位置四种步态下的加速度和角速度数据,通过直接识别行人步态的方式以及先识别手机携带位置再识别行人步态的方式,利用不同方法进行不同手机携带位置下识别行人步态的对比实验,结果均显示出本文算法有着更高的准确度和鲁棒性。下一步将研究此算法如何识别不同行人步态间的过渡转换,以实现实时的行人步态识别。

参考文献 (References):

- [1] Qiu S, Zhao H, Jiang N, et al. Multi-sensor information fusion based on machine learning for real applications in human activity recognition: State-of-the-art and research challenges[J]. Information Fusion, 2022, 80: 241-265.
- [2] 陶文元. 基于可穿戴传感的人体跌倒行为检测研究[D]. 电子科技大学, 2020.

- Tao W. Research on fall detection based on wearable sensor[D]. University of Electronic Science and Technology of China, 2020.
- [3] 邓平, 赵荣鑫, 朱飞翔. 一种基于人体运动状态识别的行人航迹推算方法[J]. 中国惯性技术学报, 2021, 29(1): 16-22.
- Deng P, Zhao R, Zhu F. A PDR algorithm based on human motion recognition[J]. Journal of Chinese Inertial Technology, 2021, 29(1): 16-22.
- [4] 段小虎, 蒋刚, 留沧海. 基于手机加速度传感器的人体步态识别研究[J]. 传感器与微系统, 2021, 40(1): 30-33+38.
- Duan X, Jiang G, Liu C. Study on human gait recognition based on cell phone acceleration sensor[J]. Transducer and Microsystem Technologies, 2021, 40(1): 30-33+38.
- [5] Gupta S. Deep learning based human activity recognition (HAR) using wearable sensor data[J]. International Journal of Information Management Data Insights, 2021, 1(2): 100046.
- [6] 郭英, 刘寒烁, 叶瑾, 等. 基于 AHDE 和手机陀螺仪的行人航向修正方法[J]. 中国惯性技术学报, 2021, 29(1): 8-15.
- Guo Y, Liu H, Ye J, et al. Pedestrian heading correction method based on AHDE and mobile phone gyroscope[J]. Journal of Chinese Inertial Technology, 2021, 29(1): 8-15.
- [7] Tiwari S, Jain V K. A novel step detection technique for pedestrian dead reckoning based navigation[J]. ICT Express, 2023, 9(1): 16-21.
- [8] 衡霞, 王忠民. 基于手机加速度传感器的人体行为识别[J]. 西安邮电大学学报, 2014, 19(6): 76-79.
- Heng X, Wang Z. Human activity recognition based on accelerometer data from a mobile phone[J]. Journal of Xi'an University of Posts and Telecommunications, 2014, 19(6): 76-79.
- [9] Qamar N, Siddiqui N, Ehatisham-ul-Hap M, et al. An approach towards position-independent human activity recognition model based on wearable accelerometer sensor[J]. Procedia Computer Science, 2020, 177: 196-203.
- [10] Daniel G G, Daniel R, Enrique F B, et al. Deep learning models for real-life human activity recognition from smartphone sensor data[J]. Internet of Things, 2023, 24: 100925.
- [11] Huang G, Zhu Q, Siew C K. Extreme learning machine: A new learning scheme of feedforward neural networks[C]//IEEE, Proceedings of the 2004 IEEE International Joint Conference on Neural Networks. Budapest, Hungary, 2004: 985-990.

(下转第 811 页)

- of high-speed spinning flying body based on AEKF[J]. Systems Engineering and Electronics, 2022, 44(06): 1977-1983.
- [13] 李荣冰, 鄢俊胜, 刘刚, 等. 基于 LSTM 深度神经网络的 MEMS-IMU 误差模型及标定方法[J]. 中国惯性技术学报, 2020, 28(02): 165-171.
- Li R, Yan J, Liu G, et al. MEMS-IMU error model and calibration method based on LSTM deep neural network[J]. Journal of Chinese Inertial Technology, 2020, 28(02): 165-171.
- [14] Mahjoub S, Chrifi-Alaoui L, Marhic B, et al. Predicting energy consumption using LSTM, multi-layer GRU, and Drop-GRU neural networks[J]. Sensors, 2022, 22(11): 4062-4072.
- [15] Liu N, Zhao H, Su Z, et al. Integrated navigation on vehicle based on low-cost SINS/GNSS using deep learning[J]. Wireless Personal Communications, 2022, 126(3): 2043-2064.
- [16] Zhai C, Wang M, Yang Y, et al. Robust vision-aided inertial navigation system for protection against ego-motion uncertainty of unmanned ground vehicle[J]. IEEE Transactions on Industrial Electronics, 2020, 68(12): 12462-12471.
- [17] Martin B, Axel B, Bonnabel S. AI-IMU dead-reckoning[J]. IEEE Transactions on Intelligent Vehicles, 2020, 5(4): 585-595.
- [18] Roux A, Changey S, Weber J, et al. CNN-based invariant extended Kalman filter for projectile trajectory estimation using IMU only[C]//2021 International Conference on Control, Automation and Diagnosis. France, 2021: 1-6.
- [19] Brossard M, Bonnabel S. Learning wheel odometry and IMU errors for localization[C]//IEEE International Conference on Robotics and Automation. Canada, 2019: 291-297.
- [20] 郭瑜, 徐博, 余志强, 等. 基于不变误差定义的 INS/USBL 紧组合导航算法[J]. 中国惯性技术学报, 2023, 31(08): 750-759.
- Guo Y, Xu B, Yu Z, et al. Invariant error definition-based tightly integrated navigation algorithm for INS/USBL[J]. Journal of Chinese Inertial Technology, 2023, 31(08): 750-759.

(上接第 802 页)

- [12] Rubio-Solis A, Panoutsos G, Beltran-Perez C, et al. A multilayer interval type-2 fuzzy extreme learning machine for the recognition of walking activities and gait events using wearable sensors[J]. Neurocomputing, 2020, 389(5): 42-55.
- [13] Tang J, Deng C, Huang G B. Extreme learning machine for multilayer perceptron[J]. IEEE Transactions on Neural Networks and Learning Systems, 2016, 27(4): 809-821.
- [14] Yuan Z, Xiong G, Fu X, et al. Improving fault tolerance in diagnosing power system failures with optimal hierarchical extreme learning machine[J]. Reliability Engineering & System Safety, 2023, 236: 109300.
- [15] Liu J, Xu H, Wang J, et al. Non-invasive diagnosis of fetal arrhythmia based on multi-domain feature and hierarchical extreme learning machine[J]. Biomedical Signal Processing and Control, 2023, 79: 104191.
- [16] Piotrowski A P, Napiorkowski J J, Piotrowska A E. Particle swarm optimization or differential evolution-a comparison[J]. Engineering Applications of Artificial Intelligence, 2023, 121: 106008.
- [17] 王迪, 王冰, 黄浩乾, 等. 复杂水下环境中自适应粒子群优化的 SINS/DVL 组合导航算法[J]. 中国惯性技术学报, 2023, 31(10): 1023-1029+1036.
- Wang D, Wang B, Huang H, et al. SINS/DVL integrated navigation method based on adaptive particle swarm optimization in complex underwater environment[J]. Journal of Chinese Inertial Technology, 2023, 31(10): 1023-1029+1036.
- [18] 王旭, 张文, 柴洪洲. 基于粒子群优化神经网络模型的 BDS-3 卫星钟差预报[J]. 中国惯性技术学报, 2023, 31(1): 33-39.
- Wang X, Zhang W, Chai H. BDS-3 satellite clock bias prediction based on particle swarm neural network[J]. Journal of Chinese Inertial Technology, 2023, 31(1): 33-39.
- [19] 刘立芳, 杨海霞, 齐小刚. 基于线性判别分析的时频域特征提取算法[J]. 系统工程与电子技术, 2019, 41(10): 2184-2190.
- Liu L, Yang H, Qi X. Time-frequency domain feature extraction algorithm based on linear discriminant analysis[J]. Systems Engineering and Electronics, 2019, 41(10): 2184-2190.
- [20] Huan S. A novel interval decomposition correlation particle swarm optimization-extreme learning machine model for short-term and long-term water quality prediction[J]. Journal of Hydrology, 2023, 625: 130034.